

Modelo de predicción lineal para costo personal del seguro médico en Estados Unidos.

Trejo Sergio* Medellín Rodrigo**

* Centro de Investigaciones en Optica, Leon, Gto (e-mail: sergiotrejo@cio.mx).

** Universidad Autónoma de Querétaro, Santiago de Querétaro, Qro.

Abstract: En este artículo se representa un modelo de regresión lineal para la predicción del costo del seguro médico. Utilizamos la base de datos USA's medical cost personal dataset proveniente de kaggle teniendo 1338 entradas. Al utilizar nuestro modelo de regresión se obtuvieron varios resultados por cada clasificación, siendo el coeficiente de determinación $r^2 = 0.8096$.

Keywords: Regresión Lineal, Insurance cost, Predicciones.

1. INTRODUCCIÓN

En el mundo actual muchas personas requieren de un seguro médico como un medio de seguridad ante cualquier amenaza que pueda afectar a su salud, pero en Estados Unidos por parte tanto de empresas de seguro privado se han desarrollado métodos para calcular el costo de los seguros médicos de las personas ya que depende de cierta demografía predecir si una persona u otra utilizará servicios hospitalarios.

Uno de los mayores predictores es si una persona fuma ya que en algún momento desarrollará cáncer de pulmón inminentemente además si una persona tiene obesidad es muy probable que desarrolle enfermedades del corazón. En análisis cualitativos realizados se encontró que los seguros varían mucho del porcentaje de ingreso anual de la persona por lo que una persona de 50 años, con un ingreso de \$500,000 dls anuales, fumador y en un plan plata es de \$42,500 dls ya que el máximo que paga una persona es de 8.5% anual.

1.1 Regresión Lineal

La regresión lineal es una herramienta mundialmente utilizada para la realización de modelos ya que permite tener una comprensión más profunda de los fenómenos complejos e intenta realizar inferencias de datos que son complicados para un humano tratar de predecir ?.

El modelo se enuncia de la siguiente forma:

$$y_i = \alpha + \beta * x + \epsilon_i \quad (1)$$

El coeficiente α representa la ordenada al origen y β el coeficiente de regresión, ϵ son las variables aleatorias independientes de la regresión.

Para entender si un modelo de regresión lineal tiene una buena aproximación se necesitan métricas para evaluarlo,

*

la primera que se tratará en éste artículo es *Mean Squared Error (MSE)*, la cuál se define como el promedio de la diferencia entre los valores predichos y los observados, ésta diferencia se eleva al cuadrado. A continuación se muestra la fórmula para calcular el MSE de la regresión.

$$MSE = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n} \quad (2)$$

Siendo y_i el valor observado, $\hat{y}_i$ y n el número de observaciones. El valor de ésta métrica se debe que al elevar al cuadrado hay un impacto significativo de los errores grandes y no penaliza en gran medida los errores pequeños.

1.2 Correlación de Pearson

La correlación de Pearson (r) es una medida estadística que evalúa la relación lineal, el rango que tiene ésta relación va de $[-1, 1]$ donde 1 es una correlación perfecta, lo que significa que todos los datos están alineados entre las dos variables cuantitativas.

La fórmula matemática para calcular la correlación de Pearson entre dos variables X y Y es:

$$r = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum (X_i - \bar{X})^2 \sum (Y_i - \bar{Y})^2}} \quad (3)$$

1.3 Algoritmo gradiente descendente

La función del gradiente es esencial en el ámbito del Deep Learning ya que permite obtener una optimización de un modelo de predicción de cualquier tipo, para obtenerlo se pretende ajustar una función lineal

$$h_{\theta}(x) = \theta_1 x + \theta_0 \quad (4)$$

y evaluar mediante la función costo de error cuadrático medio (MSE) por sus siglas en inglés:

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x_i) - y_i)^2 \quad (5)$$

el algoritmo Gradiente descendiente se repite hasta alcanzar converger. El gradiente de una función $J(\theta)$, donde $\theta = [\theta_0, \theta_1]$ se define como:

$$\nabla J(\theta_0, \theta_1) = \left[\frac{\partial J}{\partial \theta_0}, \frac{\partial J}{\partial \theta_1} \right] \quad (6)$$

de modo que el algoritmo del gradiente descendiente sería

$$\theta_0 := \theta_0 - \alpha \frac{\partial J}{\partial \theta_0} \quad (7)$$

$$\theta_1 := \theta_1 - \alpha \frac{\partial J}{\partial \theta_1} \quad (8)$$

Entonces calculamos la derivada parcial de la Ec. 5 con respecto a θ_0 y θ_1 , obteniendo que

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (h_\theta(x_i) - y_i) \frac{\partial}{\partial \theta_0} (h_\theta(x_i) - y_i) \quad (9)$$

$$\frac{\partial J}{\partial \theta_1} = \frac{1}{m} \sum_{i=1}^m (h_\theta(x_i) - y_i) \frac{\partial}{\partial \theta_1} (h_\theta(x_i) - y_i) \quad (10)$$

donde

$$\frac{\partial}{\partial \theta_0} (h_\theta(x_i) - y_i) = \frac{\partial}{\partial \theta_0} (\theta_1 x_i + \theta_0 - y_i) = 1 \quad (11)$$

$$\frac{\partial}{\partial \theta_1} (h_\theta(x_i) - y_i) = \frac{\partial}{\partial \theta_1} (\theta_1 x_i + \theta_0 - y_i) = x_i \quad (12)$$

Si se sustituye las Eq. 11, 12 en 9 y 10, y éstas últimas en 7 y 8, obtenemos

$$\theta_0 := \theta_0 - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x_i) - y_i) \quad (13)$$

$$\theta_1 := \theta_1 - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x_i) - y_i) x_i \quad (14)$$

Formando así el conjunto de ecuaciones para aproximar los parámetros θ al conjunto de datos independientes contra los datos dependientes.

1.4 Descripción del dataset

El dataset que utilizamos publicado por Miri Choi en el 2018 describe los precios que una aseguradora cobra a 1338 afiliados así como su datos personales, tales como la edad del beneficiario primario, sexo o género del beneficiario, índice de masa corporal (BMI), número de hijos cubiertos por el seguro, si es fumador o no, y región residencial de los EE.UU. los cuales pueden ser el noreste, sureste, noroeste y suroeste, dando un total de 6 variables. Una primer hipótesis que tenemos sobre los datos, es que algunos parecen tener un rango continuo, y por tanto, candidatas a realizar regresión lineal son la edad, BMI, número de hijos y cargos. Los datos que otorgan clasificación al modelo de la aseguradora son el sexo, fumador y región. El dataset ha ganado cierto grado de popularidad y ha sido utilizado en artículos, como el de Bharti and Malik (2022), donde prueban con diferentes métodos como regresión lineal, ridge o lasso, sin obtener resultados mayores a un coeficiente de ajuste R^2 de 0.85. Otros trabajos como el de ALBALAWI et al. (2023) han empleado machine learning para realizar regresiones desde las más simples como lineales hasta polinomiales, obteniendo coeficientes de ajuste R^2 de 0.96 y 0.99, respectivamente, para predicción de costos.

2. EXPERIMENTACIÓN

Para analizar nuestro dataset se imprimió el encabezado de la tabla de la base de datos mediante el atributo `.head()` y se realizó un análisis general del comportamiento de los datos. Observamos que hay valores tipo texto por lo que se cambiaron a valores enteros donde se les dio una representación: *Smoker* = 1, *NoSmoker* = 0. La tabla original se muestra en la Figura 1.

	age	sex	bmi	children	smoker	region	charges
0	19	female	27.900	0	yes	southwest	16884.92400
1	18	male	33.770	1	no	southeast	1725.55230
2	28	male	33.000	3	no	southeast	4449.46200
3	33	male	22.705	0	no	northwest	21984.47061
4	32	male	28.880	0	no	northwest	3866.85520

Fig. 1. Muestreo de nuestro dataset.

Se procedió a hacer un filtrado simple revisando los valores de dispersión máximos y mínimos, y de acuerdo con la Figura 2 los valores de charges son muy altos entonces se delimitó a tomar los valores de \$0 a \$50,000 dolares al igual que para la columna bmi se delimitó a Indices de Masa Corporal menores a 50 pts.




Fig. 2. Muestreo de nuestro dataset.

Para encontrar una relación de los valores se hizo un heatmap mostrado en la Figura 3 el cuál muestra las correlaciones de los valores de una forma gráfica y numérica, observamos que existen 3 valores que convergen con la columna charges, el cuál de ahora en adelante se convertirá en nuestro Y para el análisis siendo nuestras X, age, bmi y smoker.

Al analizar los tres valores se encontró que si hay correlaciones muy fuertes pero la dispersión de éstos valores son muy grandes, además que 'smoker' es un problema más de clasificación que de predicción, ya que no existen grados intermedios de cuanto fuman los beneficiarios contemplados por la aseguradora, por lo que de acuerdo en la Figura 4, se optó por tomar un rumbo distinto a solo un análisis de regresión.




Fig. 3. Correlaciones de nuestro Dataset.




Fig. 5. Correlaciones en el subconjunto de los fumadores




Fig. 4. Distribución de las 3 gráficas principales en relación con el Costo del Seguro de los habitantes.

2.1 División del dataset en Fumadores y No Fumadores

Para encontrar una mejor relación de los datos e incluir el factor determinante de si una persona fuma se dividió el dataset en Fumadores y No Fumadores, obteniendo para los fumadores una correlación de la edad de 0.33 (véase Figura 5) y una correlación del Índice de Masa Corporal (BMI) de 0.82 mucho más grande que el dataset original por lo que se puede determinar que el BMI en personas fumadoras es un factor muy determinante para el costo de su seguro.

En el dataset de personas NO Fumadoras (Figura 6) se determinó una correlación de la edad de 0.63 y además un factor que se puede analizar que depende un poco es el número de hijos ya que se obtuvo un 0.14 a diferencia del 0.77 que tienen los Fumadores en éste rubro.

En la Figura 7 se presenta la dispersión delimitando éstas dos categorías, en azul la de personas que no fuman y en rojo, personas que si fuman pero se puede ver que hay más estratificaciones en nuestros datos siendo en la gráfica Edad con 4 dispersiones bien definidas las cuáles comparando con nuestro dataset se ve una delimitación en $BMI = 30$, por lo que se aplicó la división explicada en la siguiente sección.




Fig. 6. Correlaciones en el subconjunto de los no fumadores




Fig. 7. Distribución del costo del seguro en relación con la Edad y el BMI, clasificando si fuman o no fuman individualmente.

2.2 División en cuatro categorías, Fumadores y Obesos

Cómo se comentó en la sección anterior, se procedió a dividir nuestros datasets en cuatro categorías, para fines

prácticos a cada uno se le determinaron siglas para su futura referencia:

- Fumadores Obesos (Smoker = Yes, BMI ≥ 30), llamados *FOB*
- Fumadores NO Obesos (Smoker = Yes, BMI < 30), llamados *FNOB*
- No Fumadores Obesos (Smoker = NO, BMI ≥ 30), llamados *NFOB*
- No Fumadores NO Obesos (Smoker = NO, BMI < 30), llamados *NFNOB*

Para lograr una mejor exploración de los cuatro datasets se calculó la matriz de correlación para cada uno. Las matrices de los fumadores obesos (Figura 8) nos dice que la variable con la que tienen mayor correlación los cargos, es la edad, la cual sabemos desde la Figura 4 que sí hay una relación proporcional, y en menor medida el BMI y la cantidad de hijos, y el género, explicando así porque el grado de dispersión de la franja de los fumadores es más grande, como se muestra en la franja roja de la Figura 12. Por el otro lado de los fumadores, los no obesos (Figura 9) solo muestran correlacion con la edad y BMI, y al tener menos variables influyendo en el costo, la franja se observa ligeramente menos dispersa en la Figura 12. En las Figuras 10 y 11 observamos gran similaridad donde solo hay una única correlación significativa del costo con la edad y una ligera correlación con los hijos.




Fig. 8. Correlaciones en el subconjunto de los fumadores

Por lo que se obtuvieron 3 categorías bien estratificadas en las gráficas de las Figuras 12 y Figura 13: los no fumadores, los fumadores no obesos y los fumadores obesos. En este caso en la gráfica BMI vs costo los dos subconjuntos de no fumadores ocupan las mismas regiones y dispersiones de costos del seguro.

2.3 Filtrado de datos por características mediante análisis visual

A nuestra Figura 12 se le aplicó una técnica de eliminación de valores atípicos por categoría en la cuál nos centramos en cada una de nuestras dispersiones y se eliminaron analizando los valores atípicos de nuestros valores como




Fig. 9. Correlaciones en el subconjunto de los no fumadores




Fig. 10. Correlaciones en el subconjunto de los fumadores

se muestra en la figura 14 donde filtramos los valores de *NFNOB* mostrados en la gráfica izquierda y en la derecha mostrando los que se utilizarán para la función del gradiente descendente.

Teniendo éstos valores ya filtrados de age se procedió a utilizar algoritmos de gradiente descendente en cada categoría para obtener una regresión lineal individualizada, se obtuvieron 4 diferentes valores de regresiones lineales los cuáles se mostrarán en la siguiente sección.

3. RESULTADOS Y DISCUSIÓN

3.1 Análisis del costo del seguro médico sin pre-procesamiento

El análisis exploratorio de datos realizado hasta ahora nos deja claro que la regresión lineal es aplicable para relacionar los costos con la edad, y la dispersión de los datos BMI vs costo nos indica que numéricamente si hay un ligero aumento del costo de manera proporcional con

Correlación de los no fumadores ni obesos




Fig. 11. Correlaciones en el subconjunto de los no fumadores




Fig. 12. Dispersión de las 4 categorías obtenidas de la variable independiente Age contra el costo del seguro médico personal.

el BMI, una pista ya sugerida por su correlación de fumadores obesos y no obesos, de 0.39 y 0.31, respectivamente.

Al hacer una regresión lineal de todos los datos de edad vs costo del seguro, se obtienen valores muy altos y con un coeficiente de determinación muy bajo o casi nulo, la regresión lineal obtenida es:

$$y = 285.3146715926712 * x + 3768.02964112238 \quad (15)$$

Representada con una línea negra en Figura 15, con un $MSE = 61,327,815.361$ además de un valor $R^2 = 0.0453850$.

Ésto nos da una pauta muy grande para hacer un análisis más certero del comportamiento ya que $R^2 = 0.045$ significa una nula relación pero al observarlo gráficamente si existe, solo se necesita aplicar un tratamiento a los datos




Fig. 13. Dispersión de las 4 categorías obtenidas de la variable independiente BMI contra el costo del seguro médico personal.




Fig. 14. Representación gráfica del filtrado de Outliers para eliminar valores atípicos relacionados con características (Children Region) que no tienen peso en nuestro análisis.

3.2 Análisis del costo del seguro médico en relación con la Edad

Todas las regresiones lineales presentadas a continuación fueron entrenadas con learning rates de 0.1 y con 5000epochs de manera individual, solamente para los valores de FOB se utilizó un learning rate de 0.05 y se utilizaron 10,000 épocas.

Todos nuestros valores utilizados fueron sin normalizar ya que la normalización se consideró un paso que no aportaba a nuestras dispersiones por el hecho de que se necesita conocer el valor exacto del costo del seguro personal predicho por la regresión lineal.

Para No Fumadores No Obesos se obtuvo una regresión lineal igual a:

$$y = 274.0859 * x - 3450.8697 \quad (16)$$

Representada con una línea azul en Figura 16, con un $MSE = 359,899.0188$ además de un valor $R^2 = 0.9468730$.

Para No Fumadores Obesos se obtuvo una regresión lineal igual a:




Fig. 15. Representación de las regresiones lineales divididas por categorías, FOB = Rojo, FNOB = Amarillo, NFOB = Verde y NFNOB = Azul.

$$y = 286.9538 * x - 3729.0004 \quad (17)$$

Representada con una línea verde en Figura 16, con un $MSE = 549,863.8165$ además de un valor $R^2 = 0.9308588$.

Se puede observar a detalle que existe una relación muy fuerte entre los valores anteriores y sus ajustes de regresión lineal, ya que R^2 la obtenemos muy próximo a 1, aunque los valores de MSE son pequeños esto se debe a los valores altos que se manejan en nuestra dispersión, ya que si se normalizara sería muy pequeño el error ya que se observa que se ajusta

Para Fumadores NO Obesos se obtuvo una regresión lineal igual a:

$$y = 233.5923 * x + 11955.4765 \quad (18)$$

Representada con una línea amarilla en Figura 16, con un $MSE = 1,581,670.1827$ además de un valor $R^2 = 0.807779$.

Para Fumadores Obesos se obtuvo una regresión lineal igual a:

$$y = 293.2716 * x + 30444.93196 \quad (19)$$

Representada con una línea roja en Figura 16, con un $MSE = 4,671,486.79247$ además de un valor $R^2 = 0.5294347$.

Podemos ver que en nuestras 4 categorías el valor de θ_1 fue muy similar ya que todas tienen una pendiente similar entre 250 – 300 dls, lo que varía en cada caso es un monto fijo dependiendo de las condiciones ya mencionadas.

3.3 Análisis del costo del seguro médico en relación con el Índice de Masa Corporal

Para el análisis de BMI, se utilizaron técnicas más sencillas ya que se decidió utilizar los datos generales de personas Fumadoras Y No Fumadoras, los resultados obtenidos se presentan en la Figura 17, obteniendo dos diferentes regresiones lineales.




Fig. 16. Representación de las regresiones lineales divididas por categorías, FOB = Rojo, FNOB = Amarillo, NFOB = Verde y NFNOB = Azul.

Para personas NO Fumadoras se obtuvo una regresión lineal en este caso de:

$$y = 19.0665 * x + 5855.4285 \quad (20)$$

Representada con una línea azul en Figura 17, con un $MSE = 19,920,681.544343$ además de un valor $R^2 = -0.1087343$.

Para personas Fumadoras se obtuvo una regresión lineal en este caso de:

$$y = 1396.85789 * x - 11897.0251632 \quad (21)$$

Representada con una línea roja en Figura 17, con un $MSE = 18,747,622.09866$ además de un valor $R^2 = 0.66181367$.




Fig. 17. Representación de las regresiones lineales divididas por categorías como variable independiente el índice de Masa Corporal, Fumadoras = Rojo y No Fumadoras = Azul.

Cómo se puede observar anteriormente en la regresión lineal de las personas No Fumadoras no se encuentra

realmente una relación lineal ni una correlación con un coeficiente de determinación $R^2 = -0.1$ ya que los datos son muy dispersos entre sí, pero en el caso de las personas fumadoras a pesar de su elevado MSE se tiene una relación más determinante que se puede observar de manera visual en la Figura anterior.

3.4 Análisis del costo del seguro médico en relación con Número de Hijos para personas No Fumadoras

Ahora se analizará solo de manera visual la relación que tiene el número de hijos de una persona con el costo que se le asigna a su seguro




Fig. 18. Esta figura se observa mejor a color

Aunque la base de datos parece tener un tope de 5 hijos, podría realizarse un análisis y una regresión lineal por cada hijo y obtener el aumento de los cargos, ya que el arreglo de los colores en la franja de los beneficiarios del seguro sin hijos tienen los cargos más bajos en promedio, y los que tienen 5 hijos tienen cargos más elevados de la franja. Con este análisis aún no se logra obtener una distinción u explicación de los cargos elevados fuera de la franja.

4. CONCLUSIONES

Al analizar visualmente los datos de BMI se esperaba una relación proporcional a los cargos que pudiéramos aplicar regresión lineal para predecir su comportamiento, sin embargo, visualmente se notó dos agrupaciones separadas entre los fumadores con una separación cerca de un BMI de 30, lo que nos dio una idea de que dicho parámetro se discretizó por la aseguradora en personas con BMI bajo y alto, o dicho en otra palabras, en personas no obesas y obesas. Al analizar visualmente los datos de la edad contra los cargos, se ve claramente tres franjas, como resultado de dicha distinción dentro del grupo de los fumadores. Al realizar la división de la base de datos en 4 grupos, fue más fácil analizar el modelo de cobro de la aseguradora, y concluimos que si el beneficiario no es fumador su seguro se mantiene en bajo costo sin importar su BMI, y basándonos en el valor de θ_0 obtenido por las regresiones, el cobro empieza con valor promedio de 3500 dólares para los beneficiarios de 18 años. Por el contrario, si es fumador sube mucho el precio del seguro, aproximadamente a 12,000 dólares para las personas de 18 años, y el cobro sube a más del doble, unos 30,400 dólares si además de fumar su BMI es mayor o igual a 30 a la edad de 18 años. Por otro

lado, el parámetro θ_1 de las cuatro regresiones indica que el cobro tiene un incremento promedio de 271.5 dólares por año de edad. Con base en el análisis de correlaciones, otros indicadores como el número de hijos es el cuarto parámetro con mayor influencia, y como ya se comentó en los resultados, visualmente se tiene una idea de que el cargo aumenta ligeramente con el número de hijos, y con cierto tratamiento de datos y una regresión lineal puede calcularse, pero al ser relativamente poco, se queda como trabajo a futuro, seguido por el género y región, éste último teniendo poca correlación con los cargos. Los resultados fueron relativamente buenos para el subconjunto de no fumadores, con R^2 mayor a 0.9, y de 0.5 y 0.8 para los dos subconjuntos de fumadores, con una simple regresión lineal y análisis de correlación, sin necesidad de emplear machine learning de alto costo.

5. ANEXOS

En esta sección se adjuntan los códigos básicos para nuestro análisis y experimentación.

Código de las librerías empleadas:

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
```

Código para mostrar la matriz de correlación:

```
f, ax = plt.subplots(1, 1,
                    figsize=(10, 10))
ax = sns.heatmap(dataset_original.corr(),
                annot=True, cmap='viridis')
ax.set_title('Matriz de correlación de nuestro DATASET', fontsize=
```

Código para separar la base de datos en fumadores y no fumadores, obesos y no obesos:

```
dataset_F = dataset.loc[dataset['smoker'] == 1]
dataset_NF = dataset.loc[dataset['smoker'] == 0]

dataset_FOB = dataset_F.loc[dataset_F['bmi'] >= 30]
dataset_FNOB = dataset_F.loc[dataset_F['bmi'] < 30]

dataset_NFOB = dataset_NF.loc[dataset_NF['bmi'] >= 30]
dataset_NFNOB = dataset_NF.loc[dataset_NF['bmi'] < 30]
```

Código de las funciones:

```
def hip(theta_0, theta_1, x):
    h = theta_1 * x + theta_0
    return h

def filtrado(x, y, theta_0, theta_1):
    n = len(x)
    filteredx = list()
    filteredy = list()
    for i in range(1, n, 1):
        h = hip(theta_0, theta_1, x[i])
        if y[i] < h:
            filteredx.append(x[i])
            filteredy.append(y[i])
    filteredx = np.array(filteredx)
    filteredy = np.array(filteredy)
    return filteredx, filteredy

def MSE(h, Y):
    return np.sum((Y - h) ** 2) / (2 * (len(Y)))

def cal_costo(X, Y, theta_0, theta_1):
    h = hip(theta_0, theta_1, X)
    cost = MSE(h, Y)
    return h, cost

def gradiente_MSE(x, y, alpha, theta_0, theta_1, epocas):
    m = len(x)
    for i in range(epocas):
        for j in range(m):
```

```

        theta_0 -= (alpha/m)*(hip(theta_0,
                                   theta_1,x[j]) - y[j])
        theta_1 -= (alpha/m)*(hip(theta_0,
                                   theta_1,x[j]) - y[j]) * x[j]

    return theta_0, theta_1

def plot(X, Y, theta_0, theta_1,col,lab):
    x = np.linspace(X.min(), X.max(), len(X))
    plt.plot(X, Y, marker='.', linestyle='none',
              label=lab, color = col)
    plt.plot(x, hip(theta_0, theta_1,x),
              label='Regresion Lineal del Modelo',
              color = 'black',linewidth = 2)
    plt.legend(loc="upper left")
    plt.xlabel('Edad')
    #plt.xlabel('Indice de Masa Corporal (BMI)')
    plt.ylabel('Costo ($)')
    plt.title('Regresion Lineal de ' + lab)
    plt.show()

def obtain_R2(h,Y):
    return (1 - sum((h-Y)**2)/sum((Y-np.mean(Y))**2))

```

Se adjunta link del Collaboratory para ver el código completo ya que el código es muy extenso: aquí.

REFERENCES

- ALBALAWI, S., ALSHAHRANI, L., ALBALAWI, N., ALHARBI, R., and ALHAKAMY, A. (2023). Prediction of healthcare insurance costs. *Computers and Informatics*, 3(1), 9–18.
- Bharti, A. and Malik, L. (2022). Regression analysis and prediction of medical insurance cost. URL <https://api.semanticscholar.org/CorpusID:247773680>.